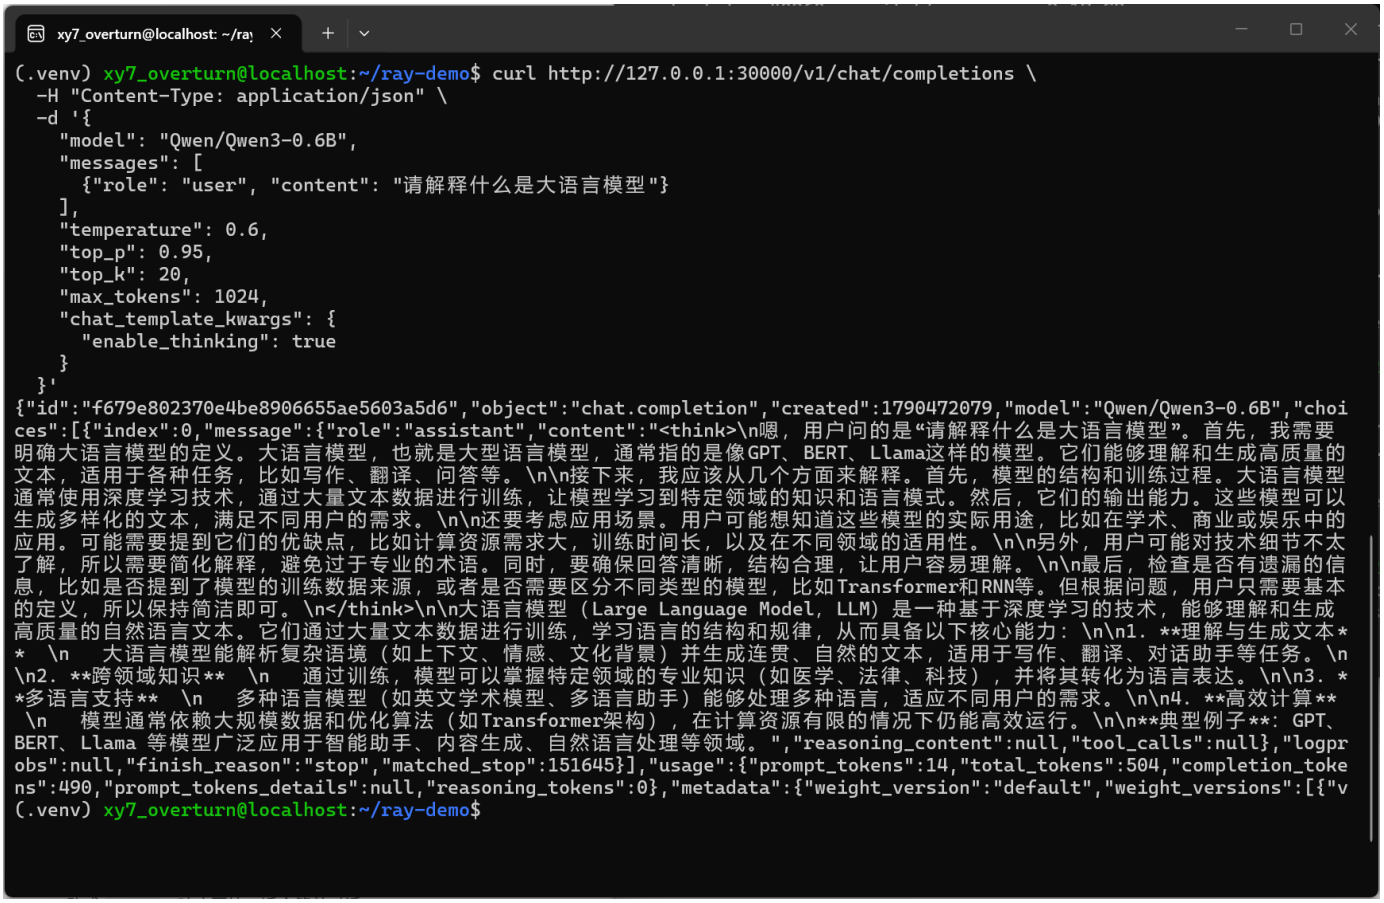
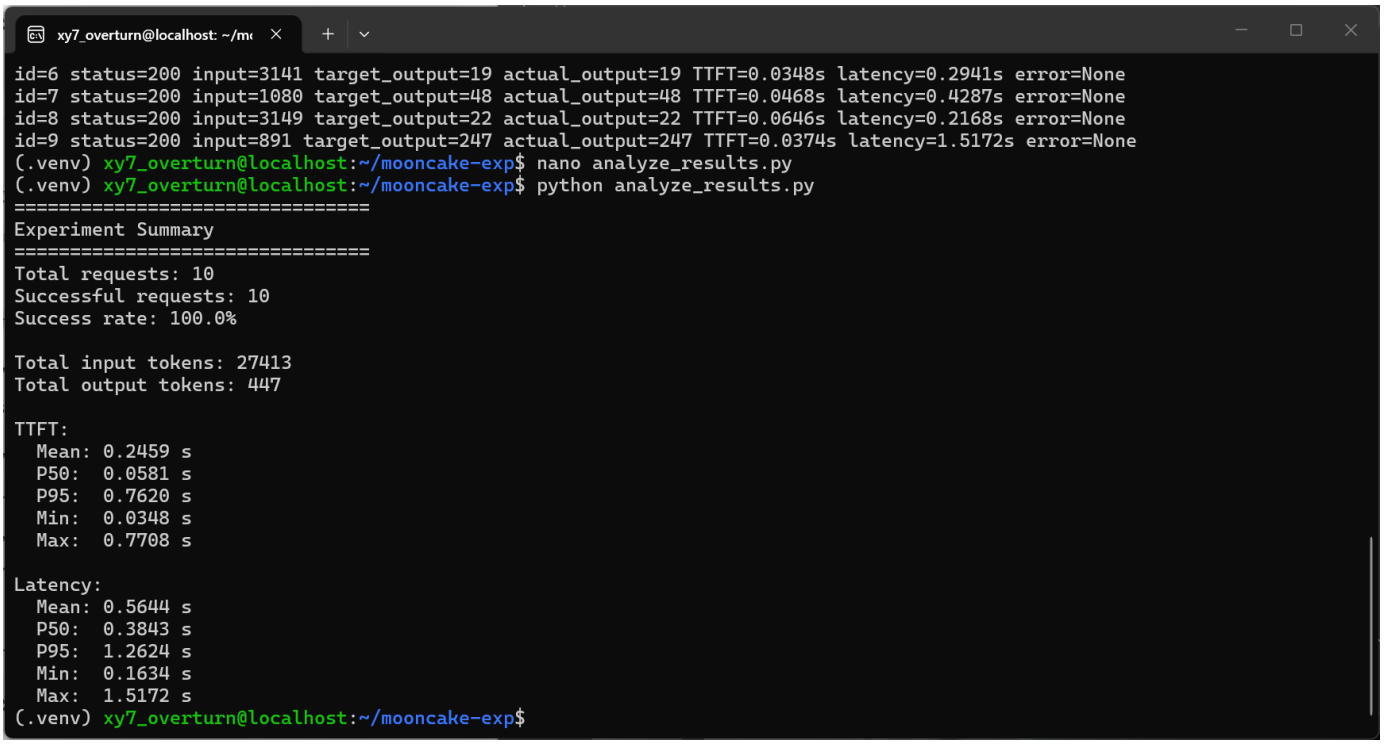

xy7_overturn@localhost: ~/ray
(.venv) xy7_overturn@localhost:~/ray-demo$ curl http://127.0.0.1:30000/v1/chat/completions \
-H "Content-Type: application/json" \
-d '{
"model": "Qwen/Qwen3-0.6B",
"messages": [
{"role": "user", "content": "请解释什么是大语言模型"}
],
"temperature": 0.6,
"top_p": 0.95,
"top_k": 20,
"max_tokens": 1024,
"chat_template_kwargs": {
"enable_thinking": true
}
}'
{"id":"f679e802370e4be8906655ae5603a5d6","object":"chat.completion","created":1790472079,"model":"Qwen/Qwen3-0.6B","choices":[{"index":0,"message":{"role":"assistant","content":"<think>\n嗯，用户问的是“请解释什么是大语言模型”。首先，我需要明确大语言模型的定义。大语言模型，也就是大型语言模型，通常指的是像GPT、BERT、Llama这样的模型。它们能够理解和生成高质量的文本，适用于各种任务，比如写作、翻译、问答等。\n\n接下来，我应该从几个方面来解释。首先，模型的结构和训练过程。大语言模型通常使用深度学习技术，通过大量文本数据进行训练，让模型学习到特定领域的知识和语言模式。然后，它们的输出能力。这些模型可以生成多样化的文本，满足不同用户的需求。\n\n还要考虑应用场景。用户可能想知道这些模型的实际用途，比如在学术、商业或娱乐中的应用。可能需要提到它们的优缺点，比如计算资源需求大，训练时间长，以及在不同领域的适用性。\n\n另外，用户可能对技术细节不太了解，所以需要简化解释，避免过于专业的术语。同时，要确保回答清晰，结构合理，让用户容易理解。\n\n最后，检查是否有遗漏的信息，比如是否提到了模型的训练数据来源，或者是否需要区分不同类型的模型，比如Transformer和RNN等。但根据问题，用户只需要基本的定义，所以保持简洁即可。\n</think>\n\n大语言模型（Large Language Model，LLM）是一种基于深度学习的技术，能够理解和生成高质量的自然语言文本。它们通过大量文本数据进行训练，学习语言的结构和规律，从而具备以下核心能力：\n\n1. **理解与生成文本** \n   大语言模型能解析复杂语境（如上下文、情感、文化背景）并生成连贯、自然的文本，适用于写作、翻译、对话助手等任务。\n\n2. **跨领域知识** \n   通过训练，模型可以掌握特定领域的专业知识（如医学、法律、科技），并将其转化为语言表达。\n\n3. **多语言支持** \n   多种语言模型（如英文学术模型、多语言助手）能够处理多种语言，适应不同用户的需求。\n\n4. **高效计算** \n   模型通常依赖大规模数据和优化算法（如Transformer架构），在计算资源有限的情况下仍能高效运行。\n\n**典型例子**：GPT、BERT、Llama 等模型广泛应用于智能助手、内容生成、自然语言处理等领域。","reasoning_content":null,"tool_calls":null},"logprobs":null,"finish_reason":"stop","matched_stop":151645}],"usage":{"prompt_tokens":14,"total_tokens":504,"completion_tokens":490,"prompt_tokens_details":null,"reasoning_tokens":0},"metadata":{"weight_version":"default","weight_versions":[{"v
(.venv) xy7_overturn@localhost:~/ray-demo$


xy7_overturn@localhost: ~/m
id=6 status=200 input=3141 target_output=19 actual_output=19 TTFT=0.0348s latency=0.2941s error=None
id=7 status=200 input=1080 target_output=48 actual_output=48 TTFT=0.0468s latency=0.4287s error=None
id=8 status=200 input=3149 target_output=22 actual_output=22 TTFT=0.0646s latency=0.2168s error=None
id=9 status=200 input=891 target_output=247 actual_output=247 TTFT=0.0374s latency=1.5172s error=None
(.venv) xy7_overturn@localhost:~/mooncake-exp$ nano analyze_results.py
(.venv) xy7_overturn@localhost:~/mooncake-exp$ python analyze_results.py
==================================
Experiment Summary
==================================
Total requests: 10
Successful requests: 10
Success rate: 100.0%
Total input tokens: 27413
Total output tokens: 447
TTFT:
Mean: 0.2459 s
P50: 0.0581 s
P95: 0.7620 s
Min: 0.0348 s
Max: 0.7708 s
Latency:
Mean: 0.5644 s
P50: 0.3843 s
P95: 1.2624 s
Min: 0.1634 s
Max: 1.5172 s
(.venv) xy7_overturn@localhost:~/mooncake-exp$