SGLang 请求处理流程

从客户端请求、前缀缓存与推理调度，到文本返回和统计信息

HTTP → Token → Text

请求接入

1 HTTP
客户端发送请求
Prompt / 参数 / 流式选项

2 API
HTTP 服务解析
校验并规范化请求

3 TOK
Tokenizer 编码
文本转换为输入 token

4 SCH
进入 Scheduler
排队、调度并分配资源

推理执行

5 CACHE
查找前缀缓存
复用匹配的 KV Cache

6 IN
Prefill
并行处理全部输入 token

7 1st
首个输出 token
完成首 token 生成

8 OUT
Decode
逐个生成后续 token

贯穿运行期

输出返回

9 BATCH
Continuous batching
运行中动态组合多个请求

10 TEXT
Detokenizer 解码
输出 token 转换回文字

11 DONE
结束并返回
响应内容与统计信息

说明：Continuous batching 在运行过程中持续参与请求调度与 Decode；虚线表示运行期控制关系。