重点回答

1）SGLang 的 RadixAttention / RadixCache 解决什么问题？

多条请求拥有相同开头时，避免模型重复计算这些相同的输入 token。
它主要减少 prefill 阶段的重复计算，从而降低 TTFT、提高吞吐量。

2）SGLang 中 page-sized KV cache 与 prefix reuse 分别对应 pipeline 中的哪一部分？

Page-sized KV cache 对应“显存管理与 attention 计算”，贯穿 prefill 和 decode。
Prefix reuse 对应“调度器准备 prefill 之前的缓存匹配”，决定哪些输入 token 可以跳过计算。

3）vLLM 的 PagedAttention 解决什么问题？它和 SGLang 的 RadixAttention/ paged KV 机制有什么联系与差异？

vLLM 的 PagedAttention 首先解决“KV Cache 如何高效放进显存”
SGLang 的 RadixAttention 主要解决“以前算过的哪些 KV Cache 可以被新请求复用”。