阅读文献笔记

具体来说，KV cache管理器通过
集中调度器发送的指令来管理KV cache工作器上的物理KV cache内存。
综上所述，PagedAttention算法允许KV块存储在非连续的物理内存中，这使得vLLM中的分页内存管理更加灵活。
分离逻辑和物理 KV 块允许 vLLM 动态增长 KV cache 内存，而无需提前为所有位置保留它，这消除了现有系统中的
大部分内存浪费。

LM 程序有两个共同的属性： (1) LM 程序通常包含多个
散布着控制流的 LLM 调用。这是完成复杂任务和提高整体质量所必需的。 (2) LM 程序接收结构化输入并产生结
构化输出。这是实现 LM 程序的组合并将 LM 程序集成到现有软件系统中所必需的。
在这些限制下，多个tokens通常可以被解码一次。然而，现有系统一次只 能解码一个 token，导致 decoding 速度不理想。
我们引入 SGLang 作为嵌入 Python 中的特定于领域的语言。它提供了生成（ 例如，extend、gen、select）和并行控制（例如，fork、join）的原语。 SGLang 与 Python 的控制流和库兼容，因此用户可以使用本机 Python 语法轻松开发高级提示工作流程。
KV cache 计算仅取决于 prefix tokens。因此，具有相同 prompt prefix 的请求可以重用 KV cache，从而减少冗余计算和内存使用。
此外，当没有缓存命中时，它仅引入可忽略不计的内存和时间开销。